

Dos ruedas, mil datos: todo lo que una bicicleta puede contar si preguntas bien

Una exploración de los patrones de uso, estaciones y movilidad del Bicing barcelonés

Ramiro Aguilar Andrade

IT Academy Data Analytics — Marzo 2026

Resumen

El presente trabajo analiza el sistema público de bicicletas compartidas de Barcelona (Bicing) mediante técnicas de análisis exploratorio de datos y visualización interactiva. Se procesaron aproximadamente 245 millones de registros del estado de las estaciones, con actualizaciones cada cuatro minutos, correspondientes al período 2019–2024, complementados con datos de usos mensuales y abonados desde 2009. El pipeline de datos, implementado en Python con Polars y Pandas, incluyó fases de ingesta, limpieza, particionado diario y agregación en paralelo, generando más de quince datasets optimizados en formato Parquet. Los resultados se materializaron en un dashboard interactivo desarrollado con Streamlit y Plotly, que permite explorar la evolución histórica del sistema, la distribución espacial de las 544 estaciones, los patrones operativos horarios y semanales, y el comportamiento individual de cada estación. Entre los hallazgos principales destacan: un crecimiento sostenido del uso tras la pandemia con un récord de 2.043.835 usos en octubre de 2025, la transición acelerada de flota mecánica a eléctrica (del 15,1% al 82,6% de los usos), patrones de commuting claramente identificables en días laborables, y la identificación de estaciones críticas con tasas de vaciado superiores al 30%.

1. Introducción

Los sistemas de bicicletas compartidas (bike-sharing) se han consolidado como un pilar de la movilidad urbana sostenible en ciudades de todo el mundo. Barcelona cuenta con Bicing, un servicio público operativo desde 2007 y gestionado actualmente por la concesionaria Pedalem Barcelona (desde mayo de 2019). El sistema conecta más de 540 estaciones distribuidas por la ciudad, con una flota de aproximadamente 8.000 bicicletas mecánicas y eléctricas, y atiende a más de 166.000 abonados.

A pesar de la riqueza de datos que genera un sistema con actualizaciones cada cuatro minutos por estación, gran parte de esta información permanece infrautilizada. El presente trabajo nace con el objetivo de explorar estos datos mediante técnicas de análisis exploratorio, visualización interactiva y agregación estadística, buscando responder preguntas como: ¿cómo ha evolucionado el uso del sistema desde 2009?, ¿qué patrones temporales y espaciales definen el comportamiento de las estaciones?, ¿qué estaciones son críticas por su tendencia a vaciarse o saturarse?

El resultado es «Dos ruedas, mil datos», un dashboard interactivo que permite navegar los hallazgos de forma intuitiva, desde la visión macro del sistema hasta el comportamiento individual de cada estación.

2. Metodología

2.1 Fuentes de datos

Se integraron tres fuentes complementarias. La primera es el dataset de Kaggle «BCN Bike Sharing Dataset – Bicing Stations», descargado automáticamente vía la API de Kaggle, que contiene el estado de cada estación (bicicletas disponibles por tipo, anclajes libres, estado operativo) con granularidad de cuatro minutos para el período marzo 2019 a marzo 2024. La segunda fuente es la API de datos abiertos del Ayuntamiento de Barcelona (Open Data BCN), que proporciona información actualizada de las estaciones, incluyendo coordenadas, capacidad, altitud y tipo de infraestructura. La tercera fuente es un archivo Excel proporcionado por el operador del servicio, con datos históricos mensuales de usos totales, usos por tipo de bicicleta, número de abonados e inventario de flota, desde 2009 hasta diciembre de 2025.

2.2 Pipeline de procesamiento

El volumen de datos (245.763.007 registros y 23 columnas tras la limpieza) exigió una arquitectura de procesamiento eficiente, estructurada en cuatro fases:

Fase 1 – Ingesta: los datasets de Kaggle se descargaron y convirtieron a Parquet; los datos de estaciones se obtuvieron vía API REST y se enriquecieron con altitudes faltantes mediante la API de Open Elevation; el Excel histórico se procesó con Pandas, incluyendo mapeo de nombres de meses del catalán al castellano y correcciones manuales de valores atípicos.

Fase 2 – Limpieza: implementada con Polars, incluyó unificación de tipos de datos entre años, eliminación de estaciones temporales o fuera del bounding box de Barcelona (como las de la Copa América), cálculo de variables derivadas (tasa de ocupación, indicadores de saturación, capacidad calculada) y filtrado de registros con estado fuera de servicio o datos inválidos.

Fase 3 – Particionado y agregación: el dataset limpio se particionó por día en estructura (fecha=YYYY-MM-DD), permitiendo la lectura perezosa (lazy evaluation) con Polars. Posteriormente, un procesamiento en paralelo (ProcessPoolExecutor) recorrió cada fecha para generar más de quince datasets agregados: resúmenes diarios por estación, patrones horarios, semanales, mensuales, rankings de estaciones críticas, series temporales globales, y datasets optimizados para mapas.

Fase 4 – Visualización: los datos agregados alimentan un dashboard interactivo de siete secciones, desarrollado con Streamlit y Plotly, con caché de recursos y mapas interactivos basados en Mapbox.

2.3 Herramientas tecnológicas

El stack tecnológico incluyó Python 3.12 como lenguaje principal, Polars para el procesamiento masivo de datos (por su rendimiento superior a Pandas en operaciones columnar sobre millones de registros), Pandas para la manipulación de datos pequeños y la lectura de Excel, Streamlit como framework de dashboarding, Plotly y Plotly Express para visualizaciones interactivas, y Mapbox para las capas geoespaciales. Todos los datasets intermedios y finales se almacenaron en formato Apache Parquet con compresión Snappy.

3. Resultados

3.1 Evolución histórica del sistema

El análisis de la serie temporal de usos mensuales (2009–2025) revela tres fases diferenciadas. Entre 2009 y 2018, el sistema mantuvo un uso relativamente estable en torno al millón de usos mensuales, con una estacionalidad marcada: octubre como mes de mayor actividad y diciembre como el de menor. En 2019 se inició la concesión de Pedalem, coincidiendo con una modernización gradual de la flota. El impacto del COVID-19 fue drástico: abril de 2020 registró apenas 21.861 usos, el mínimo histórico absoluto. A partir de 2021 comenzó una recuperación sostenida que superó los niveles prepandemia, alcanzando un récord de 2.043.835 usos en octubre de 2025. El número de abonados creció un 53,8% desde mayo de 2019, pasando de 108.000 a 166.457.

3.2 Transición de flota: mecánica a eléctrica

Uno de los hallazgos más notables es la acelerada transición hacia la bicicleta eléctrica. En 2019, las bicicletas eléctricas representaban solo el 15,1% de los usos y el 12,1% del inventario. Para 2025, la proporción de usos eléctricos alcanzó el 82,6%, mientras que el inventario se situó en un 60,6% de eléctricas en 2024. Esta asimetría entre uso e inventario indica una preferencia clara del usuario por la bicicleta eléctrica, que se utiliza proporcionalmente mucho más que su peso en la flota. La tendencia del operador apunta a una flota 100% eléctrica para 2028.

3.3 Análisis espacial

La red está compuesta por 544 estaciones con una capacidad media de 27,2 anclajes. La clasificación por tamaño muestra que el 82,1% son estaciones medianas (20–35 anclajes), el 9,0% grandes (>35) y el 8,9% pequeñas (<20). La altitud media es de 37,4 metros, con la estación más alta a 184 metros (Av. Jordà) y 85 estaciones a nivel del mar. La distancia media entre estaciones vecinas es de 205 metros, con un rango que va desde 7 metros (Pg. Lluís Companys) hasta 1.478 metros para la estación más aislada (Av. Rasos de Peguera). No se observó una correlación significativa entre altitud y capacidad de las estaciones.

3.4 Patrones operativos

El análisis operativo, basado en 512 estaciones con datos suficientes durante el período 2019–2024, reveló una ocupación media del sistema del 38,1%. El patrón horario muestra un ciclo de commuting claro en días laborables: las bicicletas abandonan las estaciones a partir de las 6:00 h (hora con más salidas), la ocupación alcanza su mínimo a las 17:00 h (hora de mayor uso), y las devoluciones se concentran hasta las 20:00 h. En la madrugada (3:00 h), el sistema se encuentra en reposo con la máxima ocupación. El heatmap hora-día confirma que este patrón se diluye los fines de semana, cuando el uso se distribuye más uniformemente.

A nivel estacional, septiembre presenta la menor proporción de bicicletas aparcadas (mayor uso), mientras que abril registra la mayor. El análisis de flujo neto permitió identificar estaciones origen (como C/ John Maynard Keynes, con flujo neto de -0,08 bicis/intervalo, típica de zonas residenciales) y estaciones destino (como Av. Paral·lel, con +0,04, asociada a zonas de oficinas y transporte). La estación más crítica del sistema (Gran Via de les Corts Catalanes, 609) pasa el 34,4% del tiempo en estado extremo, ya sea completamente vacía o llena.

4. Discusión

Los resultados confirman que el Bicing ha experimentado una transformación profunda en los últimos años. La recuperación postpandemia no solo fue rápida, sino que superó ampliamente los niveles previos, sugiriendo un cambio estructural en los hábitos de movilidad barceloneses. El crecimiento paralelo de abonados (+53,8%) y usos refuerza esta interpretación.

La preferencia por la bicicleta eléctrica es contundente: con un 60,6% del inventario, concentra el 82,6% de los usos. Esto plantea implicaciones para la planificación del operador, tanto en la gestión de la carga de baterías como en la redistribución de flota. La transición prevista a una flota 100% eléctrica parece alineada con la demanda real.

Los patrones de commuting identificados son consistentes con la literatura sobre bike-sharing en ciudades europeas, donde los días laborables presentan picos bimodales (mañana-tarde) asociados a desplazamientos trabajo-hogar. La capacidad de distinguir estaciones origen y destino a partir del flujo neto es especialmente útil para la planificación de redistribución de bicicletas, un problema operativo central en estos sistemas.

Las estaciones con tasas críticas superiores al 30% representan un área de mejora concreta: su localización geográfica y patrones temporales podrían servir para optimizar las rutas de redistribución operativa.

5. Conclusiones

Este trabajo demuestra que los datos abiertos de un sistema de bike-sharing, adecuadamente procesados, permiten extraer información accionable sobre la movilidad urbana. Se logró construir un pipeline capaz de procesar 245 millones de registros y materializarlos en un dashboard interactivo que sintetiza múltiples dimensiones del análisis: histórica, espacial y operativa.

Los principales hallazgos —crecimiento sostenido post-COVID, transición acelerada a flota eléctrica, patrones de commuting claramente identificables, y la detección de estaciones críticas— no solo tienen valor descriptivo, sino que podrían informar decisiones operativas y de planificación urbana.

Como líneas futuras, se plantea incorporar modelos predictivos de disponibilidad de bicicletas por estación, integrar datos meteorológicos como variable explicativa, y enriquecer el análisis con datos de otros modos de transporte para estudiar la intermodalidad.

6. Limitaciones

Capacidad de procesamiento: el volumen de 245 millones de registros excede la memoria RAM de equipos convencionales. Fue necesario adoptar estrategias de procesamiento perezoso (lazy evaluation), particionado por día y procesamiento en paralelo. Aún así, ciertas operaciones requirieron tiempos de ejecución considerables.

Protección de datos (RGPD): la legislación europea de protección de datos impide el acceso a información individualizada de los usuarios. No es posible conocer trayectos origen-destino, duración de viajes individuales, ni perfiles demográficos de los abonados. Esto limita el análisis a snapshots del estado de las estaciones, sin poder reconstruir flujos reales de movilidad.

Restricciones temporales: el alcance del proyecto estuvo condicionado por el marco temporal del bootcamp, lo que impidió profundizar en la construcción de modelos predictivos y la validación estadística formal de los patrones detectados.

Naturaleza de los datos: los datos son snapshots de estado (stock), no registros de transacciones (flow). Se infiere el uso a partir de cambios en la disponibilidad entre intervalos de cuatro minutos, pero no se puede distinguir entre un viaje real y una redistribución operativa realizada por camiones del servicio.

7. Referencias bibliográficas

- [1] Ajuntament de Barcelona. Portal de Datos Abiertos (Open Data BCN). Disponible en: <https://opendata-ajuntament.barcelona.cat>
- [2] Kaggle. «BCN Bike Sharing Dataset – Bicing Stations». Disponible en: <https://www.kaggle.com/datasets/>
- [3] Àrea Metropolitana de Barcelona (AMB). Pliego de condiciones técnicas del servicio Bicing (concesión 2018–2028). Disponible en: <https://www.amb.cat>
- [4] Fishman, E. (2016). Bikeshare: A Review of Recent Literature. *Transport Reviews*, 36(1), 92–119.
- [5] Bicing. Información oficial del servicio. Disponible en: <https://www.bicing.barcelona>
- [6] Polars Documentation. Disponible en: <https://pola.rs>
- [7] Streamlit Documentation. Disponible en: <https://docs.streamlit.io>